第 7 章：多 Agent 架构

> 从单个 Agent 到 Agent 团队——Claude Code 如何协调多个 Agent 并行完成复杂任务。

7.1 三种多 Agent 模式

Claude Code 支持三种多 Agent 协作模式，适用于不同复杂度的场景：

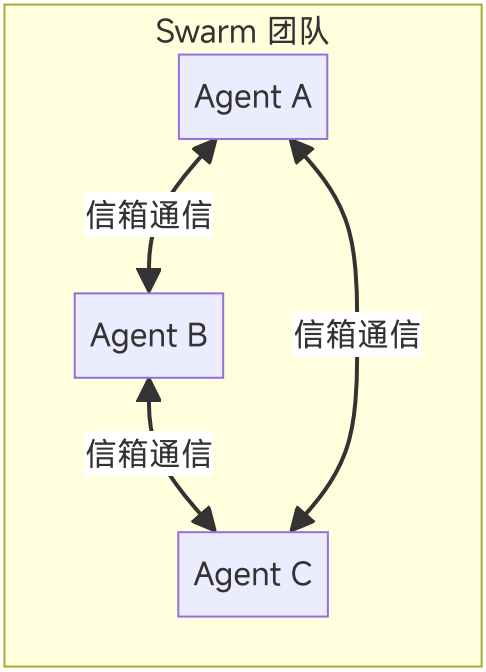
Swarm 团队
Agent A
信箱通信
Agent B
信箱通信
信箱通信
Agent C

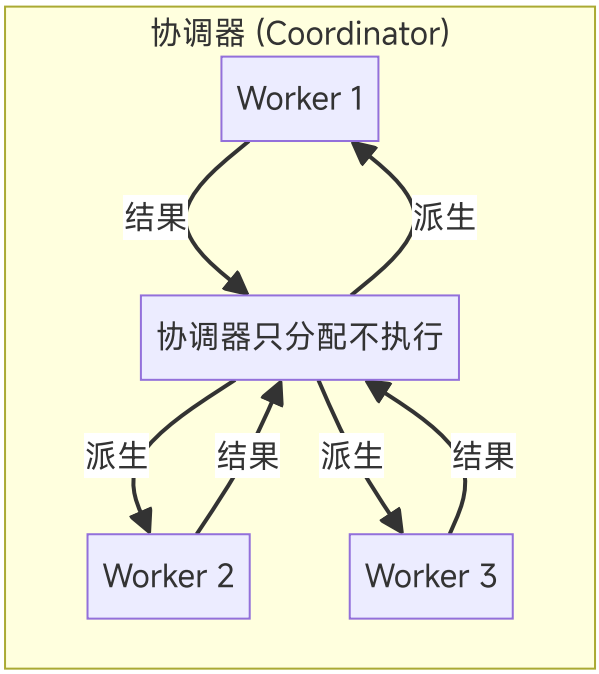
协调器 (Coordinator)
Worker 1
结果
派生
协调器只分配不执行
派生
结果
派生
结果
Worker 2
Worker 3

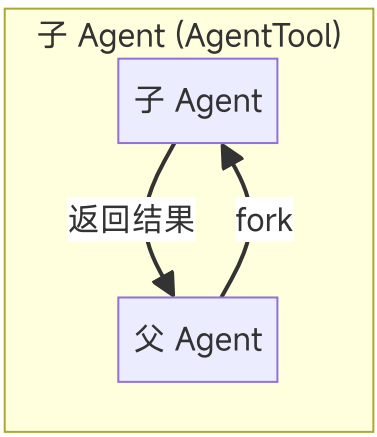
子 Agent (AgentTool)
子 Agent
返回结果
fork
父 Agent

模式	适用场景	通信方式	特点
子 Agent	单个独立子任务	fork-return	最简单，父 Agent 等待结果
协调器	复杂多步任务	派生 + 综合	协调器不执行，只编排
Swarm 团队	并行协作任务	命名信箱	Agent 间对等通信

这三种模式的复杂度递增，但共享同一套底层基础设施——`AgentTool` 工具、`ToolUseContext` 上下文隔离和 `<task-notification>` 结果通知。理解子 Agent 模式是理解后两种模式的基础。

7.2 子 Agent 模式（AgentTool）

这是最基础的多 Agent 模式。父 Agent 通过 AgentTool 派生子 Agent 执行独立任务。

关键文件：`src/tools/AgentTool/AgentTool.tsx`

完整参数解析

```typescript
{
  description: string,            // 3-5 词任务描述（必填）
  prompt: string,                 // 完整任务指令（必填）— Worker 从零开始，无
  subagent_type?: string,         // 专用 Agent 类型
  model?: 'sonnet' | 'opus' | 'haiku',  // 模型覆盖
  run_in_background?: boolean,    // 异步执行，结果通过 <task-notification>
  name?: string,                  // 可寻址名称（用于 SendMessage）
  isolation?: 'worktree' | 'remote'  // 隔离模式
}
```

关键设计：`prompt` 必须是自包含的——Worker 无法看到父 Agent 的对话历史。这意味着每个 prompt 都需要包含完成任务所需的全部信息：文件路径、行号、具体的修改内容。

为什么采用这种"无上下文"设计而非共享对话历史？原因有三：

1. **隔离性**：子 Agent 不会被父 Agent 对话中无关的信息干扰，上下文更加聚焦
2. **成本控制**：共享完整对话历史会大幅增加每次 API 调用的 token 消耗
3. **并行安全**：多个子 Agent 并行运行时，如果共享可变的对话历史会引发竞态条件

唯一的例外是 Fork 子 Agent（后文详述），它通过精巧的缓存机制在继承完整上下文的同时保持了经济性。

子 Agent 类型系统

`subagent_type` 决定了 Worker 的工具集、系统提示词和行为约束。Claude Code 源码中定义了三层 Agent 类型：

第一层：内建类型（`src/tools/AgentTool/built-in/`）

这些类型由 Claude Code 核心代码定义，经过精心优化：

类型	工具集	模型	系统提示词特点	用途
general-purpose	`['*']`（全部）	默认子 Agent 模型	最小化——"完成任务，简洁汇报"	通用任务
Explore	排除 Agent/Edit/Write/NotebookEdit	外部用 Haiku（快）；内部继承父级	严格只读 + 并行搜索优化	代码库探索
Plan	与 Explore 相同	继承父级模型	只读 + 结构化输出要求	设计实施方案

第二层：自定义类型（`.claude/agents/*.md`）

用户通过 Markdown frontmatter 定义，支持所有 `BaseAgentDefinition` 字段。例如：

```markdown
---
description: "Database migration specialist"
tools: ["Bash", "Read", "Edit"]
model: "sonnet"
permissionMode: "plan"
---
You are a database migration expert...
```

第三层：插件类型

通过插件系统注入，具有 `source: 'plugin'` 标识。

Explore Agent 深度分析

Explore Agent 的设计体现了多个精细的工程取舍（`src/tools/AgentTool/built-in/exploreAgent.ts`）：

系统提示词的"READ-ONLY"硬约束：提示词开头就用 `=== CRITICAL: READ-ONLY MODE ===` 显式声明禁止列表（不能创建/修改/删除文件、不能用重定向写文件、不能运行改变系统状态的命令）。虽然 `disallowedTools` 已经在工具层面阻止了写入工具，但系统提示词的重复声明是为了在模型层面增加一道安全屏障——模型不会尝试通过 Bash 工具间接写文件。

Haiku 模型选择：外部用户使用 Haiku（速度优先），内部用户继承父级模型。这个选择基于 Explore 的任务特性——搜索和读取文件不需要强推理能力，速度更重要。源码中的注释解释了这一点：

```typescript
// Ants get inherit to use the main agent's model; external users get h
model: process.env.USER_TYPE === 'ant' ? 'inherit' : 'haiku',
```

`omitClaudeMd: true` **的成本优化**：Explore Agent 不需要知道项目的 commit 规范、PR 模板等 CLAUDE.md 中的规则——它只读代码，由父 Agent 解读结果。源码注释揭示了这个优化的规模：

```typescript
// Explore is a fast read-only search agent — it doesn't need commit/PR
// rules from CLAUDE.md. The main agent has full context and interprets
omitClaudeMd: true,
```

> 在 34M+ 次 Explore 调用/周的规模下，省略 CLAUDE.md 可节省约 5-15 Gtok/周。

并行工具调用的速度提示：系统提示词末尾特别强调"尽可能并行调用多个工具进行搜索和文件读取"——这是利用 API 的并行工具调用能力来加速搜索。

Plan Agent 深度分析

Plan Agent（`src/tools/AgentTool/built-in/planAgent.ts`）与 Explore 共享只读工具限制，但有不同的设计目标：

结构化输出要求：系统提示词要求 Plan Agent 在输出末尾必须包含"Critical Files for Implementation"列表（3-5 个文件）。这不是可选建议——它确保规划结果是可操作的，父 Agent 能根据这些关键文件路径开始执行。

继承父级模型：与 Explore 使用 Haiku 不同，Plan 使用 `model: 'inherit'` ，因为架构设计和方案规划需要更强的推理能力。

工具列表复用： `tools: EXPLORE_AGENT.tools` ——Plan 直接引用 Explore 的工具定义，确保两者保持一致。

General-purpose Agent 设计哲学

General-purpose Agent （ `src/tools/AgentTool/built-in/generalPurposeAgent.ts` ）的设计哲学是"最小约束"：

```typescript
const SHARED_PREFIX = `You are an agent for Claude Code... Complete the fully—don't gold-plate, but don't leave it half-done.`
```

- `tools: ['*']` 赋予全部工具能力
- 不设置 `omitClaudeMd` ——因为通用 Agent 可能需要遵守项目的 commit 规范等规则
- 不指定 `model` ——使用 `getDefaultSubagentModel()` 获取默认子 Agent 模型
- 系统提示词简洁：只要求"完成任务，简洁汇报"

为什么限制工具集？ 不同任务有不同的安全需求。Explore Agent 只需要读取代码，赋予它写入能力是不必要的风险。类型系统实现了最小权限原则。

AgentTool 调用完整流程

当模型发出一次 Agent 工具调用时，系统经历以下 5 个阶段。理解这个流程有助于理解为什么子 Agent 能做到既隔离又高效。

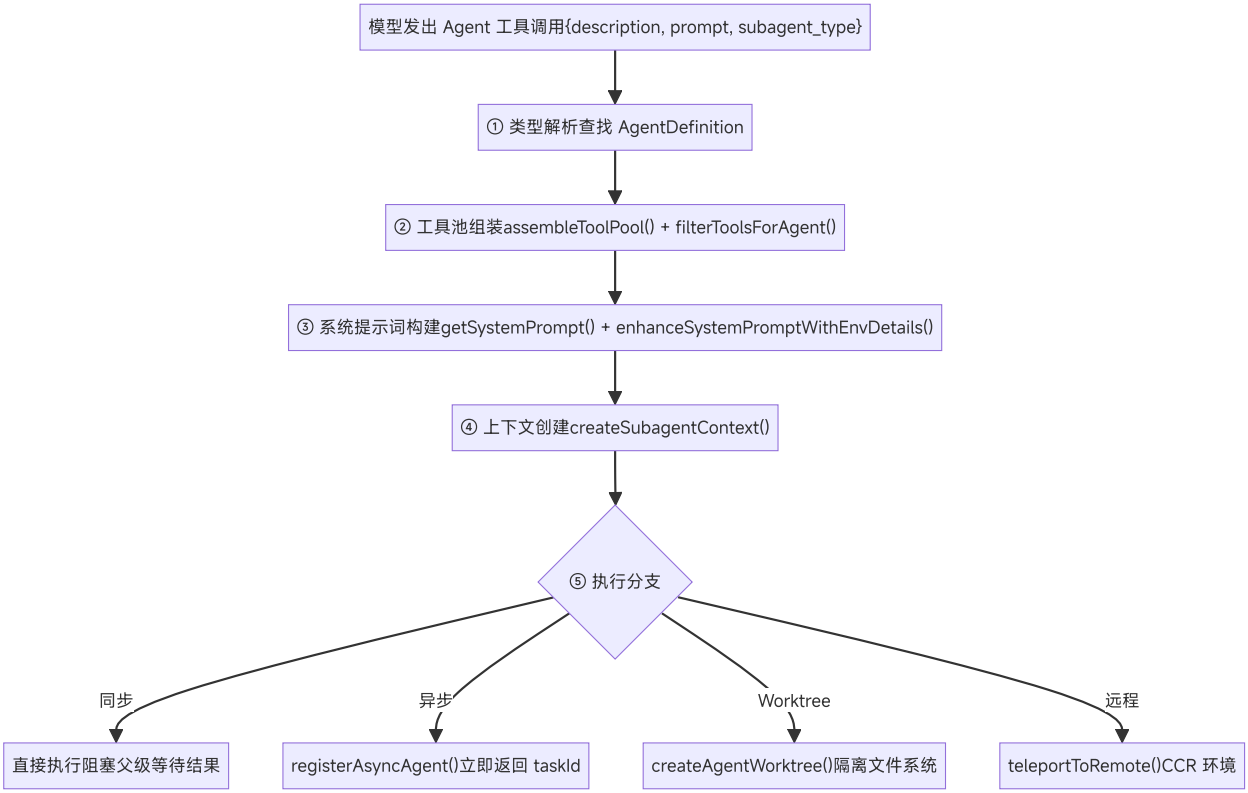

阶段 1：类型解析

类型解析的核心逻辑在 `AgentTool.tsx:318-356` ：

```typescript
// Fork subagent experiment routing:
// - subagent_type set: use it (explicit wins)
// - subagent_type omitted, gate on: fork path (undefined)
// - subagent_type omitted, gate off: default general-purpose
const effectiveType = subagent_type
  ?? (isForkSubagentEnabled() ? undefined : GENERAL_PURPOSE_AGENT.agent
const isForkPath = effectiveType === undefined;
```

这段代码的决策逻辑很巧妙：

- **显式指定类型**：直接使用，不猜测——"explicit wins"
- **省略类型 + fork 实验开启**：走 fork 路径（继承完整上下文）
- **省略类型 + fork 实验关闭**：回退到 general-purpose

如果指定了类型，系统从 `agentDefinitions.activeAgents` 列表中查找匹配的 `AgentDefinition` 。找不到时，会区分"不存在"和"被权限拒绝"两种情况，给出不同的错误提示——这对用户调试很有帮助。

阶段 2：工具池组装

子 Agent 的工具池**独立于父级**构建，这是一个关键的隔离设计（`AgentTool.tsx:568-577`）：

```typescript
// Assemble the worker's tool pool independently of the parent's.
// Workers always get their tools from assembleToolPool with their own
// permission mode, so they aren't affected by the parent's tool restri
const workerPermissionContext = {
  ...appState.toolPermissionContext,
  mode: selectedAgent.permissionMode ?? 'acceptEdits'
};
const workerTools = assembleToolPool(workerPermissionContext, appState.
```

注意 `permissionMode` 默认是 `'acceptEdits'` ——这意味着子 Agent 默认情况下可以自动执行编辑操作，无需逐个确认。这是合理的，因为子 Agent 已经由父 Agent 委托了明确的任务。

工具池组装后，还要经过 `filterToolsForAgent()` 的多层过滤（详见下文"工具过滤流水线"）。

阶段 3：系统提示词构建

普通子 Agent 和 Fork 子 Agent 的提示词构建路径完全不同（`AgentTool.tsx:483-541`）：

普通路径：

1. 调用 agent 定义的 `getSystemPrompt()` 函数获取基础提示词
2. 用 `enhanceSystemPromptWithEnvDetails()` 追加环境信息（绝对路径格式、平台信息等）
3. 用户的 `prompt` 作为一条独立的 user 消息发送

Fork 路径：

1. 直接使用父级已渲染的系统提示词字节（`toolUseContext.renderedSystemPrompt`），不重新计算
2. 用 `buildForkedMessages()` 构建消息序列（克隆父级 assistant 消息 + 占位 tool_result + 子级指令）

Fork 路径为什么不重新计算系统提示词？因为 GrowthBook（A/B 测试系统）的状态可能在父级 turn 开始和 fork 生成之间发生变化，重新计算会产生不同的字节序列，导致 Prompt Cache 失效。

阶段 4：上下文创建

`createSubagentContext()` （ `src/utils/forkedAgent.ts:345-462` ）是整个多 Agent 架构的安全基石。详见下文"上下文隔离深度解析"。

阶段 5：执行分支

执行模式的选择逻辑在 `AgentTool.tsx:555-567` ：

```typescript
const shouldRunAsync = (
  run_in_background === true ||
  selectedAgent.background === true ||
  isCoordinator ||       // 协调器模式下所有 Agent 都异步
  forceAsync ||          // fork 实验开启时所有 Agent 都异步
  assistantForceAsync    // 助手模式下强制异步
) && !isBackgroundTasksDisabled;
```

几个值得注意的设计：

- **协调器模式强制异步**：因为协调器需要同时管理多个 Worker，同步执行会阻塞编排
- **Fork 实验强制异步**：统一使用 `<task-notification>` 交互模型
- **进程内队友不能运行后台 Agent**：生命周期绑定到父级，强制后台会导致孤儿进程

工具过滤流水线

子 Agent 的工具不是简单地"给什么用什么"——而是经过一条精心设计的四层过滤流水线。这条流水线实现了**纵深防御**：即使某一层有漏洞，其他层仍能拦截危险工具访问。

关键函数： `filterToolsForAgent()` （ `src/tools/AgentTool/agentToolUtils.ts:70-116` ）

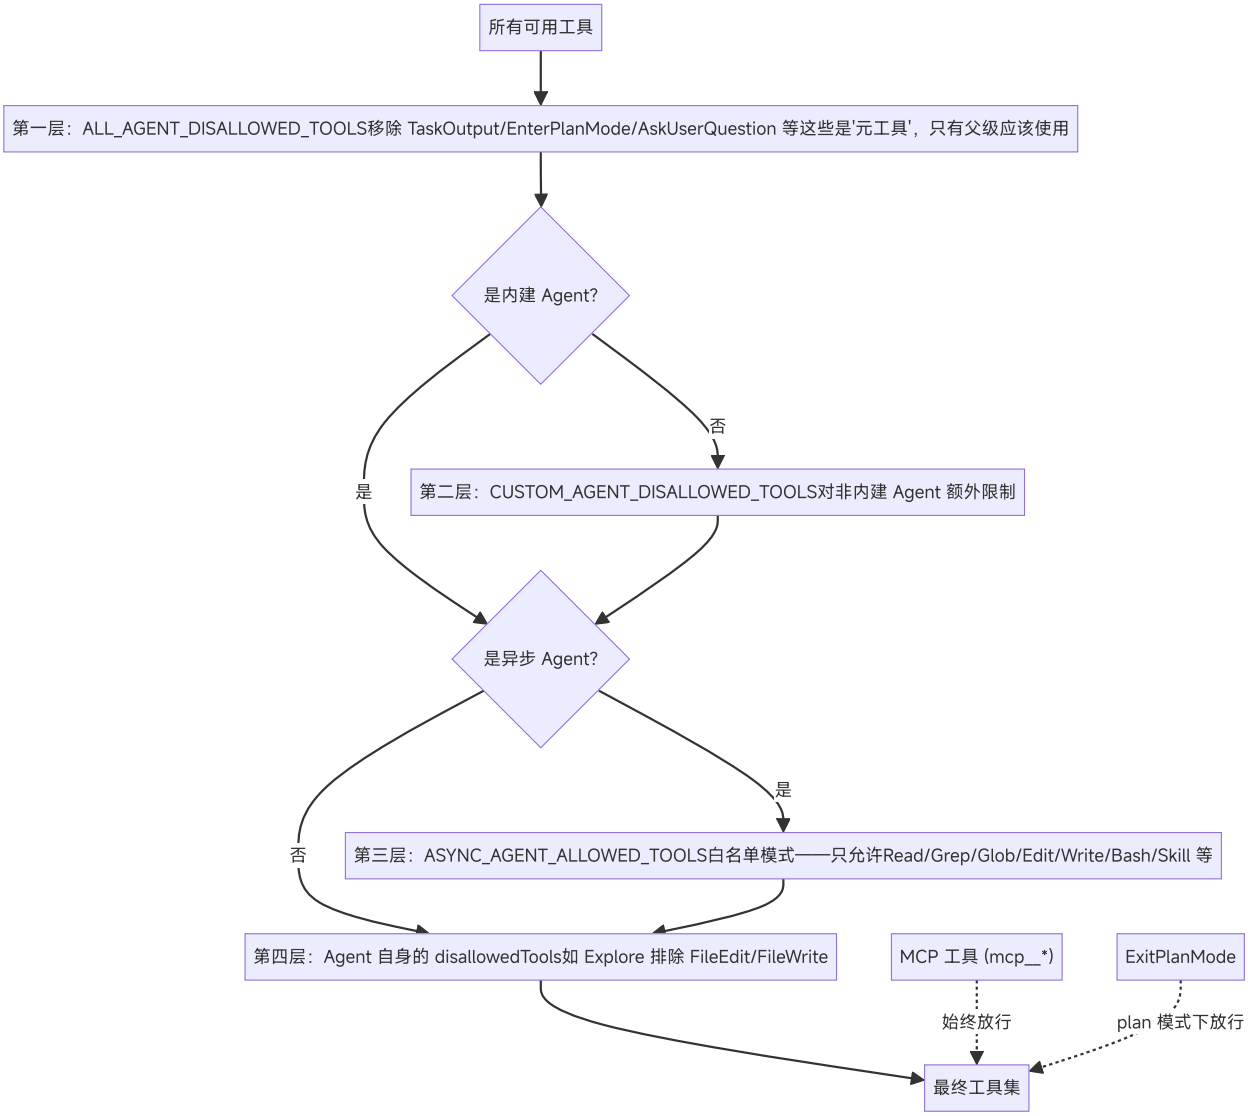

**第一层 `ALL_AGENT_DISALLOWED_TOOLS` **：移除"元工具"——TaskOutput、EnterPlanMode、ExitPlanMode、AskUserQuestion、TaskStop 等。这些工具用于控制 Agent 的执行流程本身，子 Agent 不应该能进入 Plan 模式或向用户提问。

**第二层 `CUSTOM_AGENT_DISALLOWED_TOOLS` **：对用户自定义的 Agent（来自 `.claude/agents/` ）施加额外限制。这是一个安全边界——用户定义的 Agent 类型不应该获得与内建类型相同的权限。

**第三层 `ASYNC_AGENT_ALLOWED_TOOLS` **（白名单模式）：异步 Agent 只能使用白名单中的工具（Read、Grep、Glob、Edit、Write、Bash、Skill、NotebookEdit 等）。为什么异步 Agent 需要更严格的限制？因为异步 Agent 在后台运行，无法展示交互式 UI（如权限确认弹窗），某些需要用户交互的工具必须被排除。

第三层的例外：

- **MCP 工具**（名称以 `mcp__` 开头）始终放行——它们由用户配置的外部服务提供，用户对其安全性负责
- **ExitPlanMode**：当 `permissionMode === 'plan'` 时允许——进程内队友需要退出 Plan 模式的能力

- **进程内队友**：获得额外的 Agent 工具（可以派生同步子 Agent）和任务协调工具（TaskCreate/TaskGet/TaskList/TaskUpdate/SendMessage）——这些工具使队友能够协调共享任务列表和互相通信

第四层：Agent 自身定义的 `disallowedTools` 。例如 Explore Agent 显式排除 `[Agent, ExitPlanMode, FileEdit, FileWrite, NotebookEdit]` 。

> **设计洞察**：前三层是全局策略（所有 Agent 都受约束），第四层是类型级策略（特定类型的约束）。这种分层确保了即使有人编写了一个 `disallowedTools: []` （空禁止列表）的自定义 Agent，它仍然受前三层的保护。

上下文隔离深度解析

`createSubagentContext()` （ `src/utils/forkedAgent.ts:345-462` ）是多 Agent 架构的安全基石。它为每个子 Agent 创建一个隔离的 `ToolUseContext` ，确保子 Agent 的行为不会影响父级。

核心设计原则是**"默认隔离，显式共享"**（deny by default）：所有可变状态默认是隔离的，如果需要共享必须通过 `shareSetAppState` 、 `shareAbortController` 等参数显式 opt-in。

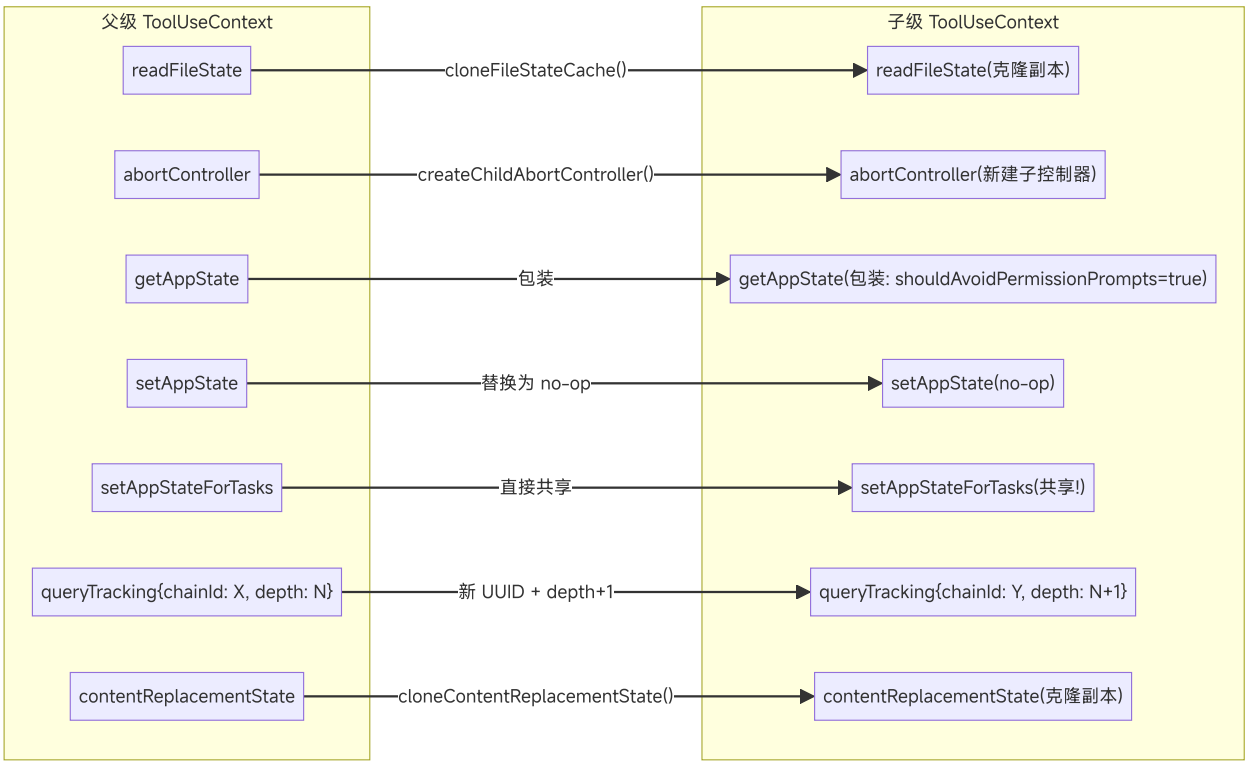

逐项解析每个字段的隔离方式和设计原因：

readFileState：克隆

```typescript
readFileState: cloneFileStateCache(
  overrides?.readFileState ?? parentContext.readFileState,
),
```

文件状态缓存记录了每个文件的最后读取时间和内容哈希。如果子 Agent 与父级共享同一个缓存，子 Agent 的文件读取会改变缓存状态，导致父级对文件新鲜度的判断出错。克隆确保子 Agent 的读取操作不会"污染"父级的缓存。

abortController：新建子控制器

```typescript
const abortController = overrides?.abortController ??
  (overrides?.shareAbortController
    ? parentContext.abortController
    : createChildAbortController(parentContext.abortController))
```

`createChildAbortController()` 使用 `WeakRef` 创建一个链接到父级的子控制器。关键行为：

- **父级中断 → 子级也中断**：通过事件监听器传播 abort 信号
- **子级中断 ≠ 父级中断**：子级的 abort 只清理自己的监听器，不影响父级

这个单向传播是故障隔离的基础：一个子 Agent 的失败（被 abort）不会连锁影响父级或其他子 Agent。

getAppState：包装

```typescript
getAppState: overrides?.shareAbortController
  ? parentContext.getAppState  // 交互式子 Agent 直接共享
  : () => {
      const state = parentContext.getAppState()
      return {
        ...state,
        toolPermissionContext: {
          ...state.toolPermissionContext,
          shouldAvoidPermissionPrompts: true,  // 关键!
        },
```

```
      }
    }
```

非交互式子 Agent（后台运行）的 `getAppState` 被包装为始终返回 `shouldAvoidPermissionPrompts: true`。这防止后台子 Agent 弹出权限确认对话框阻塞父级的终端——后台 Agent 没有地方显示 UI。

setAppState：默认 no-op

```typescript
setAppState: overrides?.shareSetAppState
  ? parentContext.setAppState
  : () => {},  // 隔离：子 Agent 的状态变更不传播
```

子 Agent 的状态变更（如工具进度、响应长度）默认不会传播到父级 UI。这避免了多个并行子 Agent 同时更新 UI 导致的混乱。

setAppStateForTasks：始终共享

```typescript
// Task registration/kill must always reach the root store, even when
// setAppState is a no-op — otherwise async agents' background bash tas
// are never registered and never killed (PPID=1 zombie).
setAppStateForTasks:
  parentContext.setAppStateForTasks ?? parentContext.setAppState,
```

这是唯一一个即使 `setAppState` 是 no-op 也必须共享的回调。为什么？因为子 Agent 可能通过 Bash 工具启动后台进程。如果这些进程的注册信息到不了根 store，当子 Agent 结束时这些进程就成了僵尸进程——PPID=1，无人回收。

queryTracking：新 chainId + depth + 1

```typescript
queryTracking: {
  chainId: randomUUID(),            // 每个子 Agent 一个新的链路 ID
  depth: (parentContext.queryTracking?.depth ?? -1) + 1,
}
```

这个字段有两个作用：

1. **防止无限递归**：depth 递增使系统能够检测和限制 Agent 嵌套深度
2. **链路追踪**：chainId 允许分析系统追踪 Agent 的家族谱系，用于性能分析和调试

contentReplacementState：克隆（非新建）

```typescript
// Clone by default (not fresh): cache-sharing forks process parent
// messages containing parent tool_use_ids. A fresh state would see
// them as unseen and make divergent replacement decisions → wire
// prefix differs → cache miss.
contentReplacementState:
  overrides?.contentReplacementState ??
  (parentContext.contentReplacementState
    ? cloneContentReplacementState(parentContext.contentReplacementStat
    : undefined),
```

这个字段的处理方式特别精妙。它管理工具结果中的内容替换（如截断超长输出）。为什么用克隆而不是新建？因为 Fork 子 Agent 会处理包含父级 `tool_use_id` 的消息。如果用一个全新的状态，对同一个 `tool_use_id` 会做出不同的替换决策，导致 API 请求的字节序列不同——Prompt Cache 就失效了。克隆确保对已知 ID 做出相同的决策，维持缓存命中。

四种执行模式

模式	实现	结果传递	适用场景
同步	进程内直接执行	结果嵌入父对话	简单子任务
异步	`LocalAgentTask`	`<task-notification>` XML	长时间任务
队友	Tmux/iTerm2/InProcess 会话	信箱通信	并行协作
远程	`RemoteAgentTask`	WebSocket 流式	CCR 环境

同步模式是最简单的：父 Agent 阻塞等待子 Agent 完成，结果直接作为 `tool_result` 嵌入父级对话。适合快速的探索或搜索任务。

异步模式适合长时间运行的任务。 `registerAsyncAgent()` 在 `AppState.tasks` 中注册任务状态，父 Agent 立即收到一个包含 `agentId` 和 `outputFile` 的响应，可以继续处理其他工作。任务完成时， `enqueueAgentNotification()` 将 `<task-notification>` XML 作为 user 角色消息投递到父级的下一轮对话中。

自动后台化：当同步 Agent 运行超过 120 秒（ `getAutoBackgroundMs()` ），系统自动将其转为后台任务，避免长时间阻塞父级：

```typescript
function getAutoBackgroundMs(): number {
  if (isEnvTruthy(process.env.CLAUDE_AUTO_BACKGROUND_TASKS) ||
      getFeatureValue_CACHED_MAY_BE_STALE('tengu_auto_background_agents
    return 120_000;
  }
  return 0;
}
```

隔离模式

Git Worktree 隔离：子 Agent 在独立的 Git Worktree 中工作，防止多个 Agent 同时修改同一文件：

```
主仓库 (main branch)
├── Agent A 在此工作
│
├── .git/worktrees/
│   ├── worktree-abc/     ← Agent B 的隔离副本
│   └── worktree-def/     ← Agent C 的隔离副本
```

Worktree 创建过程（ `src/utils/worktree.ts` ）：

1. **Slug 验证**：最长 64 字符，只允许字母数字和 `./-/_` ，禁止路径穿越（ `..` 、绝对路径）——这是安全边界，防止子 Agent 通过 slug 注入访问仓库外的文件
2. **创建**：在 `.claude/worktrees/<slug>/` 下创建，对大目录（如 `node_modules` ）使用符号链接避免磁盘占用
3. **清理**：任务完成后，如果 worktree 无任何文件变更（通过 `git diff` 检测），自动删除；有变更时返回路径和分支名，由用户决定是否合并

远程隔离：在远程 CCR（Cross-Continent Runtime）环境中执行，通过 WebSocket 流式传输消息，适用于需要完全隔离的沙盒环境。远程隔离始终以异步模式运行。

Fork 子 Agent

当 `subagent_type` 未指定且 `FORK_SUBAGENT` feature gate 启用时，系统创建 **fork 子 Agent**——一种特殊模式，继承父级完整对话上下文。

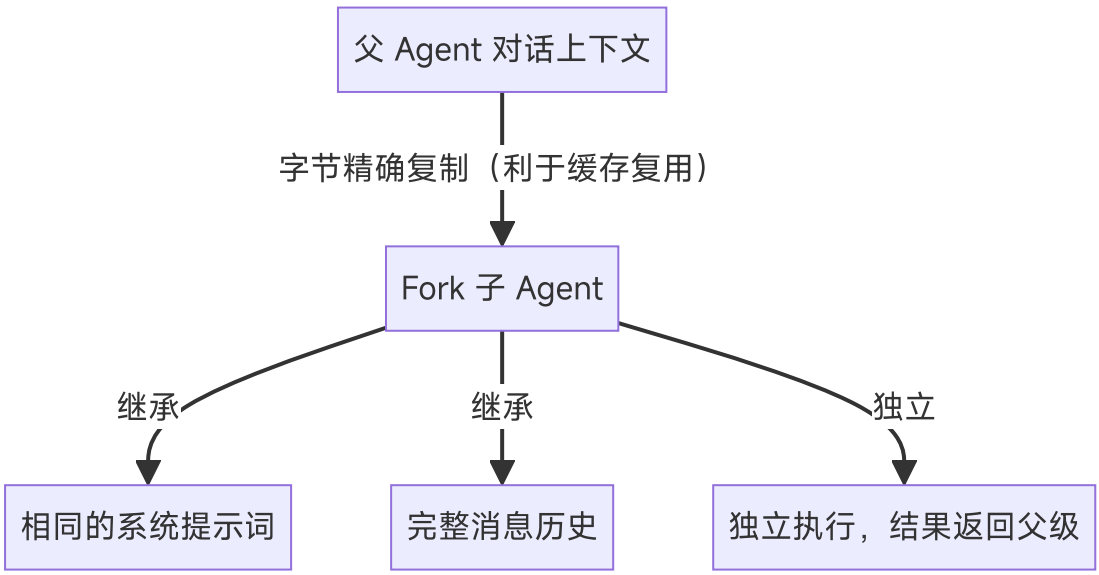

为什么需要 Fork？Prompt Cache 的经济学

Fork 机制的核心动机是 **Prompt Cache 共享**。理解这一点需要先理解 Anthropic API 的缓存机制：

API 按请求前缀（system prompt + tools + messages prefix）缓存。如果两个请求的前缀字节完全相同，第二个请求可以复用第一个的缓存，cache read token 比 input token 便宜 90%。

普通子 Agent 有自己的系统提示词和空的消息历史——它与父级的请求前缀完全不同，无法共享缓存。每次调用都是"冷启动"。

Fork 子 Agent 则不同：它**继承父级的完整请求前缀**（相同的系统提示词、相同的工具定义、相同的消息历史），只在末尾追加一条不同的指令。这意味着所有从同一个父级 fork 出来的子 Agent 都共享同一个缓存前缀——第一个 fork 是冷启动，后续的都是缓存命中。

源码中 `CacheSafeParams` 类型（`forkedAgent.ts:57-68`）明确了这个"字节级相同"的要求：

```typescript
export type CacheSafeParams = {
  /** System prompt - must match parent for cache hits */
  systemPrompt: SystemPrompt
  /** User context - prepended to messages, affects cache */
  userContext: { [k: string]: string }
  /** System context - appended to system prompt, affects cache */
  systemContext: { [k: string]: string }
  /** Tool use context containing tools, model, and other options */
  toolUseContext: ToolUseContext
  /** Parent context messages for prompt cache sharing */
```

```
  forkContextMessages: Message[]
}
```

Fork 消息构建

`buildForkedMessages()` （ `forkSubagent.ts:107-169` ）是 fork 机制的核心——它构建一组消息，确保所有 fork 子级的请求前缀字节相同：

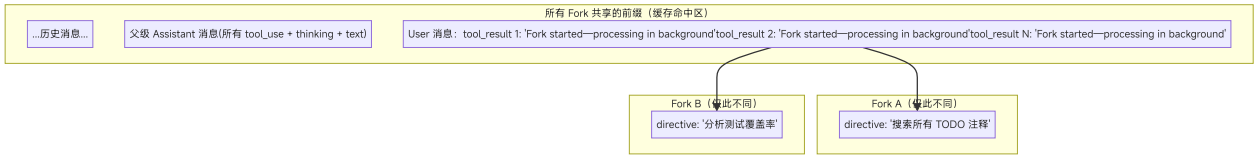

关键实现细节：

1. **克隆父级 assistant 消息**：保留所有内容块（thinking、text、每个 tool_use），不修改——确保字节相同
2. **占位 tool_result**：为每个 tool_use 生成一个 tool_result，文本统一为 `"Fork started — processing in background"` 。为什么不用实际结果？因为实际结果各不相同，会破坏缓存前缀的一致性
3. **Per-child directive**：只有最后一个文本块是每个 fork 独有的——包含该 fork 需要执行的具体指令

递归 Fork 防护

Fork 子级的工具池中保留了 Agent 工具（为了缓存一致性——如果移除会改变工具定义的字节），但在运行时通过两道防线阻止递归 fork：

```typescript
// 第一道：通过 querySource 检测（抗消息压缩）
if (toolUseContext.options.querySource === `agent:builtin:${FORK_AGENT.

// 第二道：扫描消息历史中的 FORK_BOILERPLATE_TAG（后备方案）
|| isInForkChild(toolUseContext.messages)
```

为什么需要两道？ `querySource` 是在 context 的 options 中设置的，不受消息自动压缩（autocompact）的影响——这是首选方案。消息扫描是后备方案，覆盖 `querySource` 没有被正确传递的边缘情况。

Fork Agent 定义

```typescript
export const FORK_AGENT = {
  agentType: 'fork',
  tools: ['*'],              // 全部工具，保持与父级缓存一致
  maxTurns: 200,
  model: 'inherit',          // 继承父级模型（上下文长度对等）
  permissionMode: 'bubble',  // 权限请求冒泡到父级终端
  getSystemPrompt: () => '', // 未使用—fork 直接使用父级已渲染的系统提示词
}
```

`permissionMode: 'bubble'` 是一个独特的权限模式——当 fork 子级需要权限确认时，请求会"冒泡"到父级的终端显示，而不是被静默拒绝。这是因为 fork 子级被设计为"父级的延伸"，它的操作在概念上仍然由用户控制。

`getSystemPrompt: () => ''` 看起来像一个 bug，但实际上是刻意设计——fork 路径从不调用这个函数，而是直接传入父级的 `renderedSystemPrompt` 字节。如果不小心调用了它（比如代码路径错误），空字符串会导致明显的异常，而不是一个微妙的缓存失效。

与协调器模式互斥：Fork 和协调器不能同时启用——协调器有自己的 Worker 委托机制，fork 的"继承完整上下文"设计与协调器的"Worker 从零开始"哲学相矛盾。

7.3 协调器模式（Coordinator）

协调器模式（Feature-gated: `COORDINATOR_MODE`）将主 Agent 转变为**纯编排者**——只负责分析任务、分配 Worker、综合结果，永远不直接操作文件。

关键文件：`src/coordinator/coordinatorMode.ts`

协调器角色定义

协调器的系统提示词由 `getCoordinatorSystemPrompt()` 生成，包含 6 个精心设计的部分：

部分	内容	核心约束
1. Your Role	定义协调器职责	"Direct workers, synthesize results, communicate with user"

部分	内容	核心约束
2. Your Tools	Agent, SendMessage, TaskStop	"Do not use workers to trivially report file contents"
3. Workers	Worker 能力和工具集	subagent_type 必须为 `worker`
4. Task Workflow	四阶段工作流 + 并发管理	"Parallelism is your superpower"
5. Writing Worker Prompts	提示词编写规范	"Never write 'based on your findings'"
6. Example Session	完整的多轮交互示例	从研究到修复的端到端流程

协调器可用工具

协调器的工具集被严格限制——这是核心设计约束：

工具	用途
`Agent`	派生新 Worker
`SendMessage`	继续已有 Worker（利用其加载的上下文）
`TaskStop`	终止 Worker（方向错误时的止损）
`subscribe_pr_activity`	订阅 GitHub PR 事件（若可用）

协调器**不能**使用 Bash、Edit、Read 等工具——这确保它只做编排，不做执行。内部工具（TeamCreate, TeamDelete, SendMessage, SyntheticOutput）从主线程中排除。

为什么协调器不能执行？ 这不仅仅是分工问题——如果协调器既做决策又做执行，它会倾向于"自己动手比委托更快"，从而退化为一个普通的单 Agent。工具集的硬限制强制它必须通过 Worker 完成所有实际操作，这保证了任务分配的客观性和并行化。

Worker 工具集

Worker 根据模式获得不同的工具：

```typescript
// src/coordinator/coordinatorMode.ts
const workerTools = isEnvTruthy(process.env.CLAUDE_CODE_SIMPLE)
  ? [BASH_TOOL_NAME, FILE_READ_TOOL_NAME, FILE_EDIT_TOOL_NAME]  // 简单模
  : Array.from(ASYNC_AGENT_ALLOWED_TOOLS)                       // 完整
      .filter(name => !INTERNAL_WORKER_TOOLS.has(name))
```

- **简单模式**（`CLAUDE_CODE_SIMPLE`）：Bash, Read, Edit
- **完整模式**：`ASYNC_AGENT_ALLOWED_TOOLS` 中的所有工具（排除内部工具）
- MCP 工具自动可用
- 技能通过 SkillTool 委托

Worker 工具上下文注入

`getCoordinatorUserContext()` 做了一件看似简单但至关重要的事：它构建一个 `workerToolsContext` 字符串，注入到协调器的用户上下文中。这个字符串告诉协调器：

1. **Worker 有哪些工具**——协调器需要知道 Worker 的能力边界才能写出可行的 prompt（不会要求 Worker 使用它没有的工具）
2. **有哪些 MCP 服务器可用**——如果连接了 Slack MCP，协调器就知道可以派 Worker 发消息
3. **Scratchpad 目录路径**——如果启用了 Scratchpad，协调器可以指导 Worker 在共享目录中写入发现

这是**上下文工程在编排层面的体现**——协调器不是在盲目委托，而是根据 Worker 的实际能力来制定可行的任务计划。

标准工作流

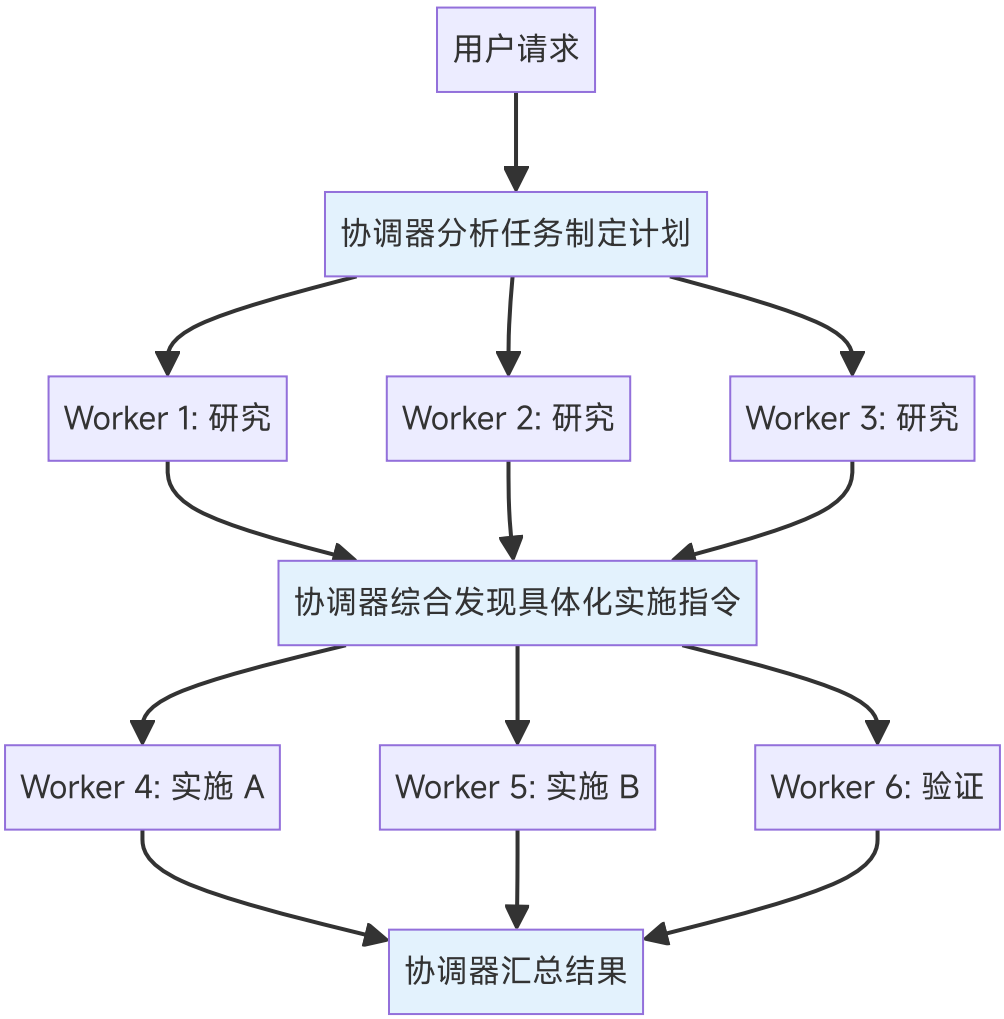

四个阶段的并发管理规则：

阶段	并发策略	原因
研究	自由并行	只读操作，无冲突风险
综合	协调器串行	必须理解所有发现后才能下发指令
实施	按文件集串行	同文件写入必须串行化，防止冲突
验证	可与不同文件区域的实施并行	验证不修改被测代码

协调器提示词设计精要

`getCoordinatorSystemPrompt()` 中蕴含了多条经过实践验证的设计原则：

1. "Never write 'based on your findings'"

协调器必须自己理解研究结果，然后写出包含具体文件路径、行号和修改内容的实施指令。"Based on your findings" 是将理解能力委托给 Worker，违背了协调器的核心职责。

```
// 反模式 — 懒惰委托
Agent({ prompt: "Based on your findings, fix the auth bug" })

// 正确 — 综合后的具体指令
Agent({ prompt: "Fix the null pointer in src/auth/validate.ts:42.
  The user field on Session is undefined when sessions expire but
  the token remains cached. Add a null check before user.id access." })
```

为什么这条规则如此重要？因为它定义了协调器的**不可委托职责**——综合理解。如果协调器只是转发消息（"Worker A 发现了一些东西，Worker B 你去处理"），它就退化成了一个消息路由器，没有任何智能编排的价值。强制协调器在综合阶段"理解并具体化"，是保持编排质量的关键。

2. "Every message you send is to the user"

这条规则防止协调器在长时间运行时保持沉默。Worker 的 `<task-notification>` 是内部信号，不是对话伙伴——协调器不应该回复通知，而应该向用户报告进展。

3. "Don't set the model parameter"

协调器提示词中明确要求不要为 Worker 设置 `model` 参数。原因是 Worker 默认使用与协调器相同的模型来处理实质性任务。如果协调器为了"节省成本"设置了更便宜的模型，Worker 在复杂实施任务中可能表现不佳——这是一个容易犯的错误。

4. "Add a purpose statement"

协调器被要求在 Worker prompt 中包含"目的声明"——例如"This research will inform a PR description"。这是微妙但重要的提示工程：Worker 知道产出的用途后，会调整输出的深度和格式。为 PR 描述做的研究会更注重用户可见的变化，为 bug 修复做的研究会更注重根因分析。

5. Continue vs Spawn 决策表

场景	决策	原因
研究探索了需要编辑的文件	**Continue**	Worker 已有文件上下文
研究范围广但实施范围窄	**Spawn**	避免探索噪声，聚焦上下文更干净
纠正失败或扩展最近工作	**Continue**	Worker 有错误上下文
验证其他 Worker 刚写的代码	**Spawn**	验证者应以新鲜视角审视

场景	决策	原因
上次实施方法完全错误	**Spawn**	错误上下文会锚定重试思路

最后一条特别有深意：当一个 Worker 的方法完全错误时，它的对话历史中充满了错误的假设和失败的尝试。如果继续使用这个 Worker，模型倾向于基于已有上下文做小修小补（"锚定效应"），而不是从根本上换一种方法。Spawn 一个全新的 Worker 可以避免这种认知锚定。

6. "验证 = 证明代码有效，不是确认代码存在"

验证 Worker 必须：运行测试（启用功能）、调查类型检查错误（不轻易判定"无关"）、保持怀疑态度、独立测试。

7. Worker 看不到你的对话

每个 Worker 提示词必须是自包含的。协调器提示词中反复强调这一点："Workers can't see your conversation. Every prompt must be self-contained."

这是初学者最容易犯的错误——写出类似"请继续刚才的工作"的 prompt，但 Worker 根本不知道"刚才"是什么。

7.4 Swarm 执行后端

Swarm 系统支持创建**命名 Agent 团队**，Agent 之间通过信箱对等通信。

关键文件： `src/utils/swarm/backends/`

三种后端

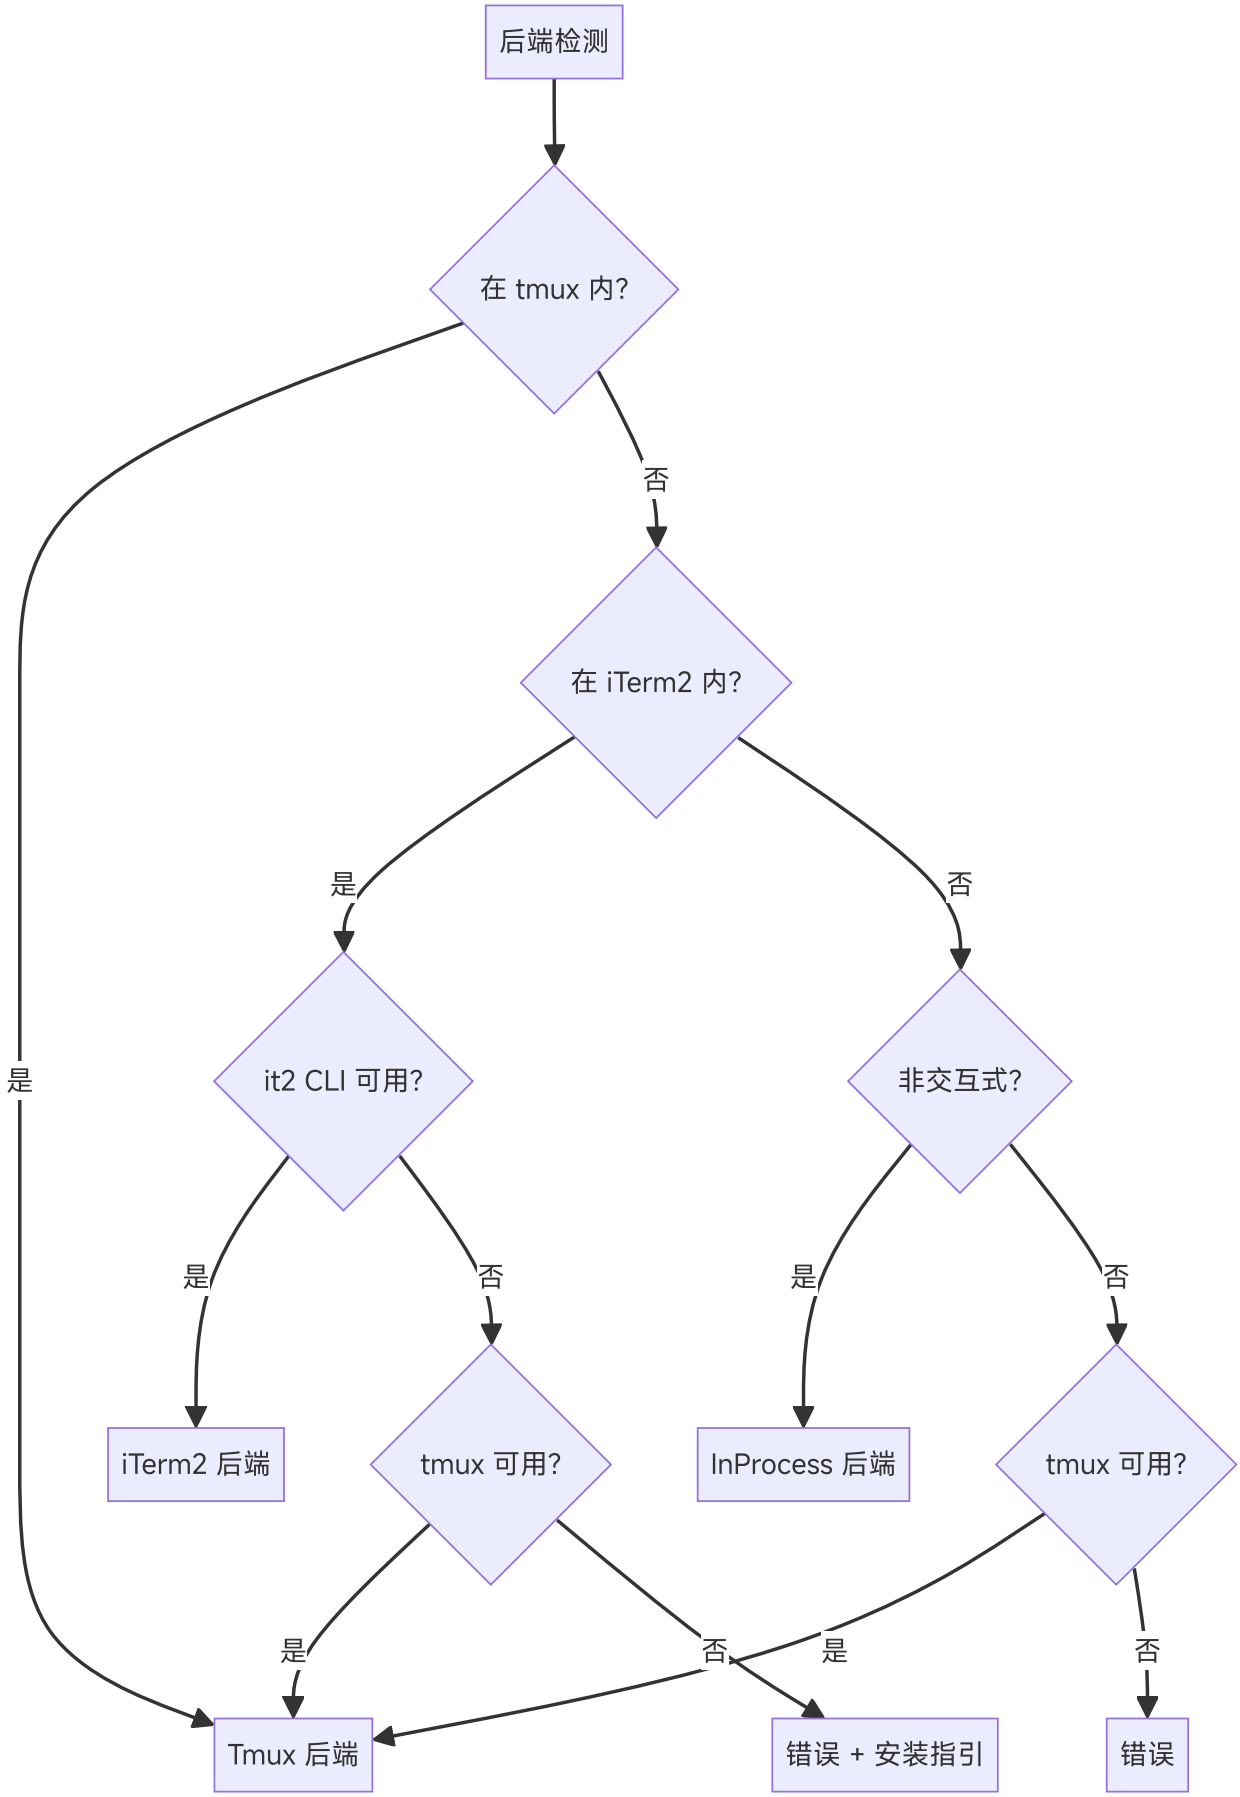

后端	实现方式	特点
Tmux	创建/管理 tmux 分屏面板	支持隐藏/显示，最常用

后端	实现方式	特点
iTerm2	原生 iTerm2 面板（via `it2` CLI）	macOS 原生体验
InProcess	同一 Node.js 进程内运行	AsyncLocalStorage 隔离，共享 API 客户端和 MCP 连接

后端选择优先级的设计考量

后端检测的优先级不是随意排列的，每一步都有明确的理由：

1. **已在 tmux 内 → 直接用 Tmux**：用户已经有了 tmux 分屏基础设施，在 tmux 内再创建新的 tmux session 会造成嵌套混乱。直接利用现有环境最自然。
2. **在 iTerm2 内 + `it2` CLI 可用 → 用 iTerm2**：提供 macOS 原生的面板体验（创建/分割窗格而非 tmux 面板），但如果 `it2` CLI 不可用则回退到 tmux——因为 iTerm2 环境中 tmux 通常也可用。
3. **非交互式环境 → InProcess**：CI/CD、SDK 调用等没有终端的场景，无法创建可视化面板。InProcess 后端在同一进程内运行 Worker，是唯一可行的选择。
4. **其他交互式环境 → 尝试 tmux**：如果都不满足，尝试 tmux 作为最后方案。tmux 几乎在所有 Linux/macOS 系统上可用。

统一接口

所有后端实现统一的 `TeammateExecutor` 接口：

```typescript
interface TeammateExecutor {
  spawn(config): Promise<void>                // 创建队友
  sendMessage(agentId, message): Promise<void>  // 发送消息
  terminate(agentId, reason): Promise<void> // 优雅关闭
  kill(agentId): Promise<void>                // 立即终止
  isActive(agentId): boolean                  // 检查存活
}
```

`terminate` 和 `kill` 的区别很重要：`terminate` 发送优雅关闭请求（Agent 可以完成当前工作再退出），`kill` 通过 AbortController 立即中断。协调器在 Worker 方向错误时使用 `TaskStop`（映射到 kill），在正常结束时使用 terminate。

InProcess 执行详解

InProcess 后端是最轻量的执行方式，适用于非交互式环境（如 CI/CD）。核心文件：`src/utils/swarm/inProcessRunner.ts`。

AsyncLocalStorage 上下文隔离：

每个 Worker 通过 `runWithTeammateContext()` 在独立的 AsyncLocalStorage 上下文中运行。Node.js 的 AsyncLocalStorage 提供了一种在异步调用链中传递上下文的机制——每个 Worker 的异步调用栈（Promise 链、回调等）都能访问自己的 `TeammateIdentity`，即使它们在同一个 Node.js 事件循环中交错执行。

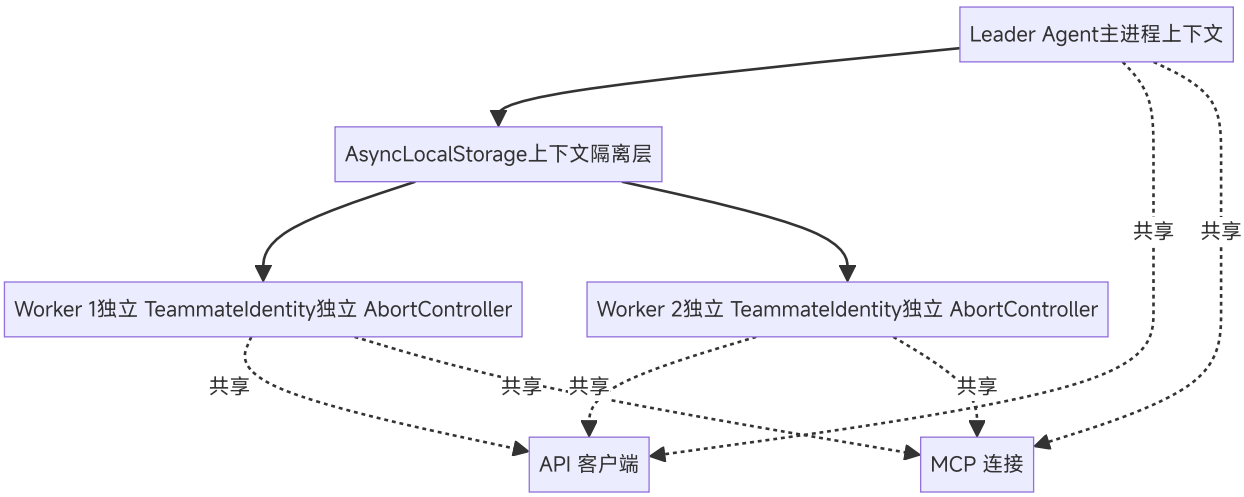

为什么 API 客户端和 MCP 连接可以共享？因为它们本质上是无状态的连接复用——HTTP 客户端和 WebSocket 连接是线程安全的，多个 Worker 可以并发使用同一个连接而不会干扰。这避免了为每个 Worker 建立独立连接的开销（TCP 握手、TLS 协商、MCP 初始化等）。

权限同步机制：

Worker 执行工具时需要权限审批。InProcess 后端使用两种权限桥接方式：

1. **Leader 桥接**（优先）：Worker 直接调用 Leader 的 `ToolUseConfirm` 对话框，UI 上显示 Worker 标记（badge）让用户知道是哪个 Worker 在请求。这是快速路径——权限确认直接在终端弹出，用户立即看到并做出决策。

2. **信箱通信**（后备）：Worker 将权限请求写入信箱（`writeToMailbox`），Leader 通过 `readMailbox` 读取并响应。通过 `registerPermissionCallback()` / `processMailboxPermissionResponse()` 实现。这是当 Leader 桥接不可用时的后备方案——例如 Leader 正忙于处理其他请求。

AbortController 独立性：

每个 Worker 有独立的 AbortController。这意味着：

- 一个 Worker 的失败不影响其他 Worker

- 协调器中断不级联到 Worker（Worker 可以被显式 TaskStop）
- `killInProcessTeammate()` 通过 abort controller 立即终止特定 Worker

Scratchpad：跨 Worker 知识共享

当 `tengu_scratch` feature gate 启用时，系统提供一个共享的 Scratchpad 目录：

```typescript
// src/coordinator/coordinatorMode.ts
if (scratchpadDir && isScratchpadGateEnabled()) {
  content += `\nScratchpad directory: ${scratchpadDir}\n` +
    `Workers can read and write here without permission prompts. ` +
    `Use this for durable cross-worker knowledge.`
}
```

Workers 可以在这个目录中自由读写文件（无需权限确认），用于持久化跨 Worker 的知识——例如研究发现、中间结果、共享配置。

为什么需要 Scratchpad? 没有它，Worker 之间只能通过协调器中转信息。这有两个问题：

1. **延迟**：Worker A 的发现必须先回传给协调器，协调器综合后再传给 Worker B——多了一个来回
2. **信息丢失**：协调器综合时可能丢失细节（比如具体的行号），Worker B 拿到的是协调器的理解而非原始发现

Scratchpad 提供了一个直接的旁路通道：Worker A 将详细发现写入文件，Worker B 直接读取——无需经过协调器的"理解和转述"。

7.5 Worker 结果传递

同步 vs 异步：两条返回路径

Worker 的结果传递分为同步和异步两条路径，它们的机制完全不同：

同步路径（`finalizeAgentTool()` in `agentToolUtils.ts`）：

当子 Agent 同步执行时，父 Agent 阻塞等待。完成后，系统提取子 Agent 最后一条 assistant 消息的文本内容（不包含中间的工具调用过程），包装为 `AgentToolResult`，直接作为 `tool_result` 嵌入父级对话。

```typescript
// 同步结果结构
{
  status: 'completed',
  agentId: string,
  content: [{ type: 'text', text: '最终结果文本' }],
  totalToolUseCount: number,
  totalDurationMs: number,
  totalTokens: number,
}
```

异步路径（`enqueueAgentNotification()` in `LocalAgentTask.tsx`）：

异步 Agent 在后台运行，父 Agent 立即收到一个"已启动"的响应。当任务完成（成功/失败/被终止）时，结果以 `<task-notification>` XML 格式作为 **user 角色消息**投递到父级的下一轮对话中：

```xml
<task-notification>
  <task-id>ae9a65ee22594487c</task-id>
  <status>completed</status>
  <summary>Agent "research query engine" completed</summary>
  <result>
    ... 详细结果内容 ...
  </result>
  <usage>
    <total_tokens>71330</total_tokens>
    <tool_uses>21</tool_uses>
    <duration_ms>81748</duration_ms>
  </usage>
</task-notification>
```

关键字段：

- `task-id`：Agent ID，可用于 `SendMessage` 继续该 Worker
- `status`：`completed` / `failed` / `killed`
- `summary`：人类可读的结果摘要（"completed" / "failed: {error}" / "was stopped"）
- `result`：Worker 的文本输出（可选），协调器据此做综合决策
- `usage`：Token 使用量、工具调用次数、耗时——用于成本追踪

task-notification 以 user 角色消息到达。协调器通过 `<task-notification>` 开头标签区分它们和真正的用户消息。这个设计选择是因为 Claude API 的消息格式要求——只有 user 角

色的消息能由系统注入，而 `<task-notification>` 本质上是一个"系统事件"而非真正的用户输入。

通知去重与安全检查

去重机制：`enqueueAgentNotification()` 使用一个原子 `notified` 标志（`LocalAgentTask.tsx`）防止重复通知。如果 TaskStop 已经标记了任务为已通知，后续的完成通知会被静默丢弃。这防止了一个 Worker 被 stop 后又恰好自然完成时向协调器发送两条通知。

安全分类器：当 `TRANSCRIPT_CLASSIFIER` feature gate 启用时，`classifyHandoffIfNeeded()`（`agentToolUtils.ts`）在返回子 Agent 结果给父级之前，对子 Agent 的完整对话记录运行安全分类。这是一种**纵深防御**机制——防止攻击者通过精心构造的文件内容（如 README 中嵌入的 prompt injection）利用子 Agent 作为"跳板"，将恶意指令注入父级对话。如果分类器标记了结果，安全警告会被前置到结果文本中。

Worker 生命周期

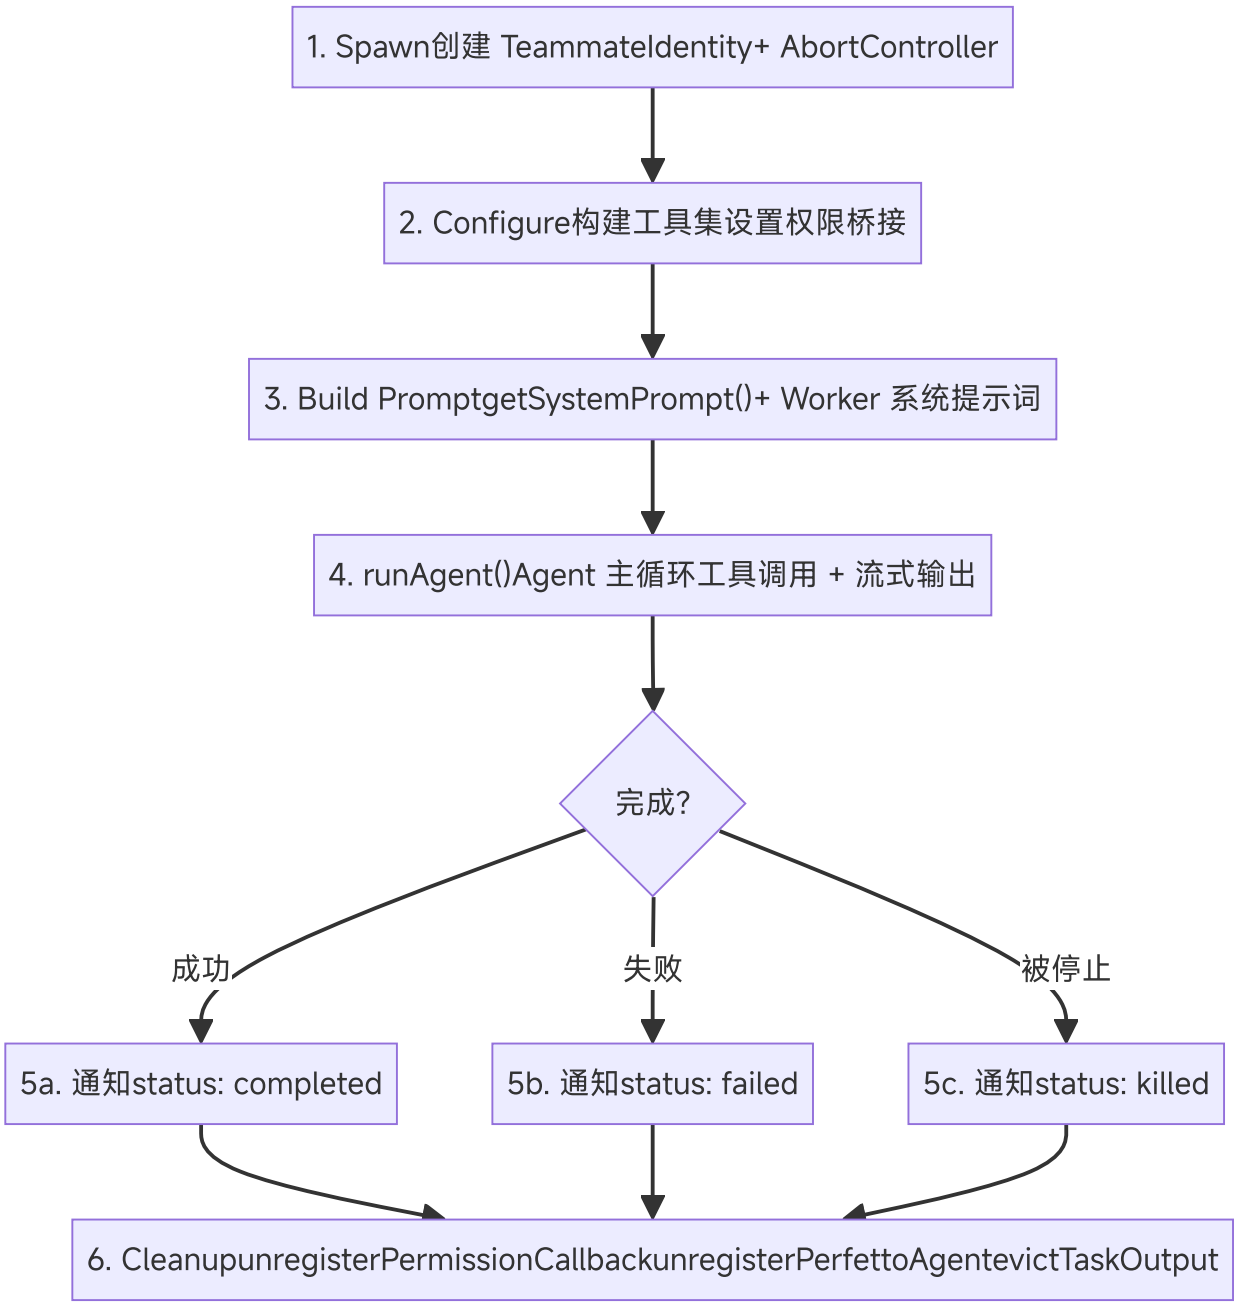

错误处理与恢复

Worker 失败时，协调器有多种恢复策略：

场景	推荐策略	原因
测试失败	`SendMessage` 继续同一 Worker	Worker 有完整的错误上下文
方法完全错误	Spawn 新 Worker	避免错误上下文锚定重试思路
Worker 被 TaskStop	可 `SendMessage` 重新定向	被停止的 Worker 可以继续
多次纠正失败	报告给用户	可能需要人类判断

协调器提示词中明确指出处理策略：

```
When a worker reports failure:
- Continue the same worker with SendMessage — it has the full error con
- If a correction attempt fails, try a different approach or report to
```

7.6 Plan 模式：两阶段执行

Plan 模式在 Agent 的工具调用循环中插入了一个**审批关卡**——进入 Plan 模式后，系统级剥离写入权限，Agent 只能读取代码和撰写计划文件；用户审批计划后，权限恢复，Agent 按计划执行修改。

关键文件：`src/tools/EnterPlanModeTool/` 、 `src/tools/ExitPlanModeTool/` 、 `src/utils/planModeV2.ts` 、 `src/utils/plans.ts`

两阶段设计

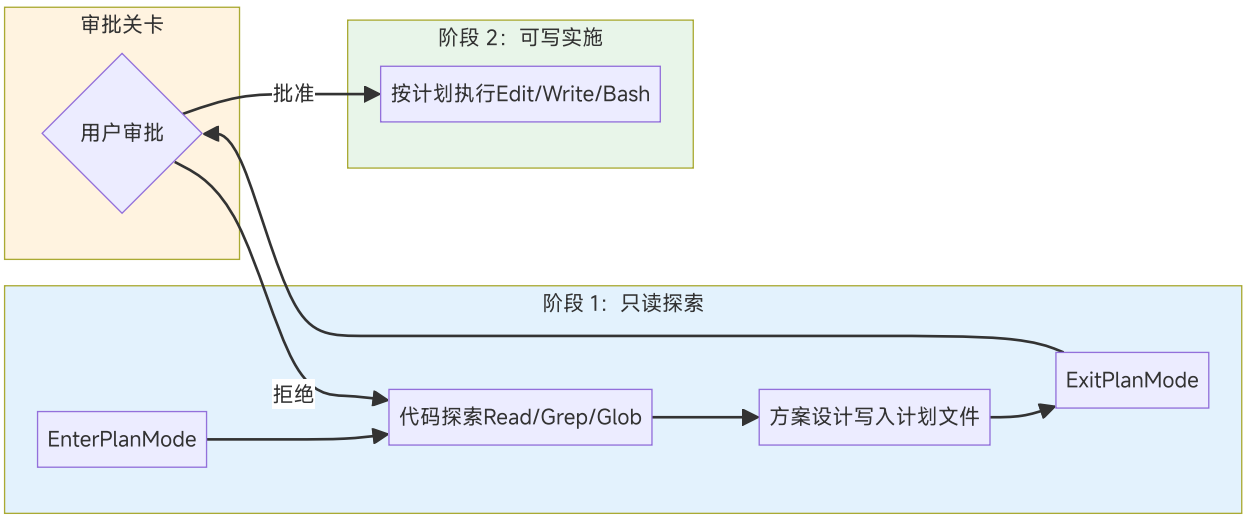

阶段	权限模式	可写范围	Agent 行为
探索	`plan`	仅计划文件	只读工具 + Explore/Plan 子 Agent
实施	恢复原模式	全部已授权工具	按审批通过的计划执行

权限剥离与恢复

进入 Plan 模式时，系统执行精细的权限管理：

```typescript
// src/utils/permissions/permissionSetup.ts
function prepareContextForPlanMode(context: ToolPermissionContext) {
  // 1. 记住进入 Plan 前的权限模式（如 default/auto）
  //    退出时恢复到这个模式
  context.prePlanMode = context.mode

  // 2. 如果从 auto 模式进入，剥离危险权限
  //    防止自动分类器在探索阶段批准写入操作
  if (context.mode === 'auto') {
    stripDangerousPermissionsForAutoMode(context)
  }

  // 3. 切换到 plan 模式
  context.mode = 'plan'
}
```

被剥离的"危险权限"包括：Bash 工具级别的 allow 规则、脚本解释器前缀（ `python:*` 、 `node:*` 等）、Agent 通配符（ `agent(*)` ）。这些权限在用户审批计划后自动恢复。

> **设计决策：为什么不直接禁用所有写入工具？**
>
> Plan 模式保留了一个可写表面——计划文件（存储在 `~/.claude/plans/{slug}.md` ）。Agent 需要将探索发现和设计方案持久化到这个文件中，供用户审阅。这个"只允许写计划文件"的设计，在安全性（不修改代码）和实用性（能产出可审阅的方案）之间取得了平衡。

Plan 模式的五阶段工作流

系统提示词（ `src/utils/messages.ts` ）为 Plan 模式定义了一个结构化的工作流：

1. **初步理解** — 使用 Explore 子 Agent 调查代码库
2. **方案设计** — 使用 Plan 子 Agent 设计实现方案
3. **方案审查** — 读取关键文件，确保方案可行
4. **编写计划** — 将最终方案写入计划文件（唯一可编辑的文件）
5. **退出 Plan** — 调用 ExitPlanMode，触发用户审批

审批与状态转换

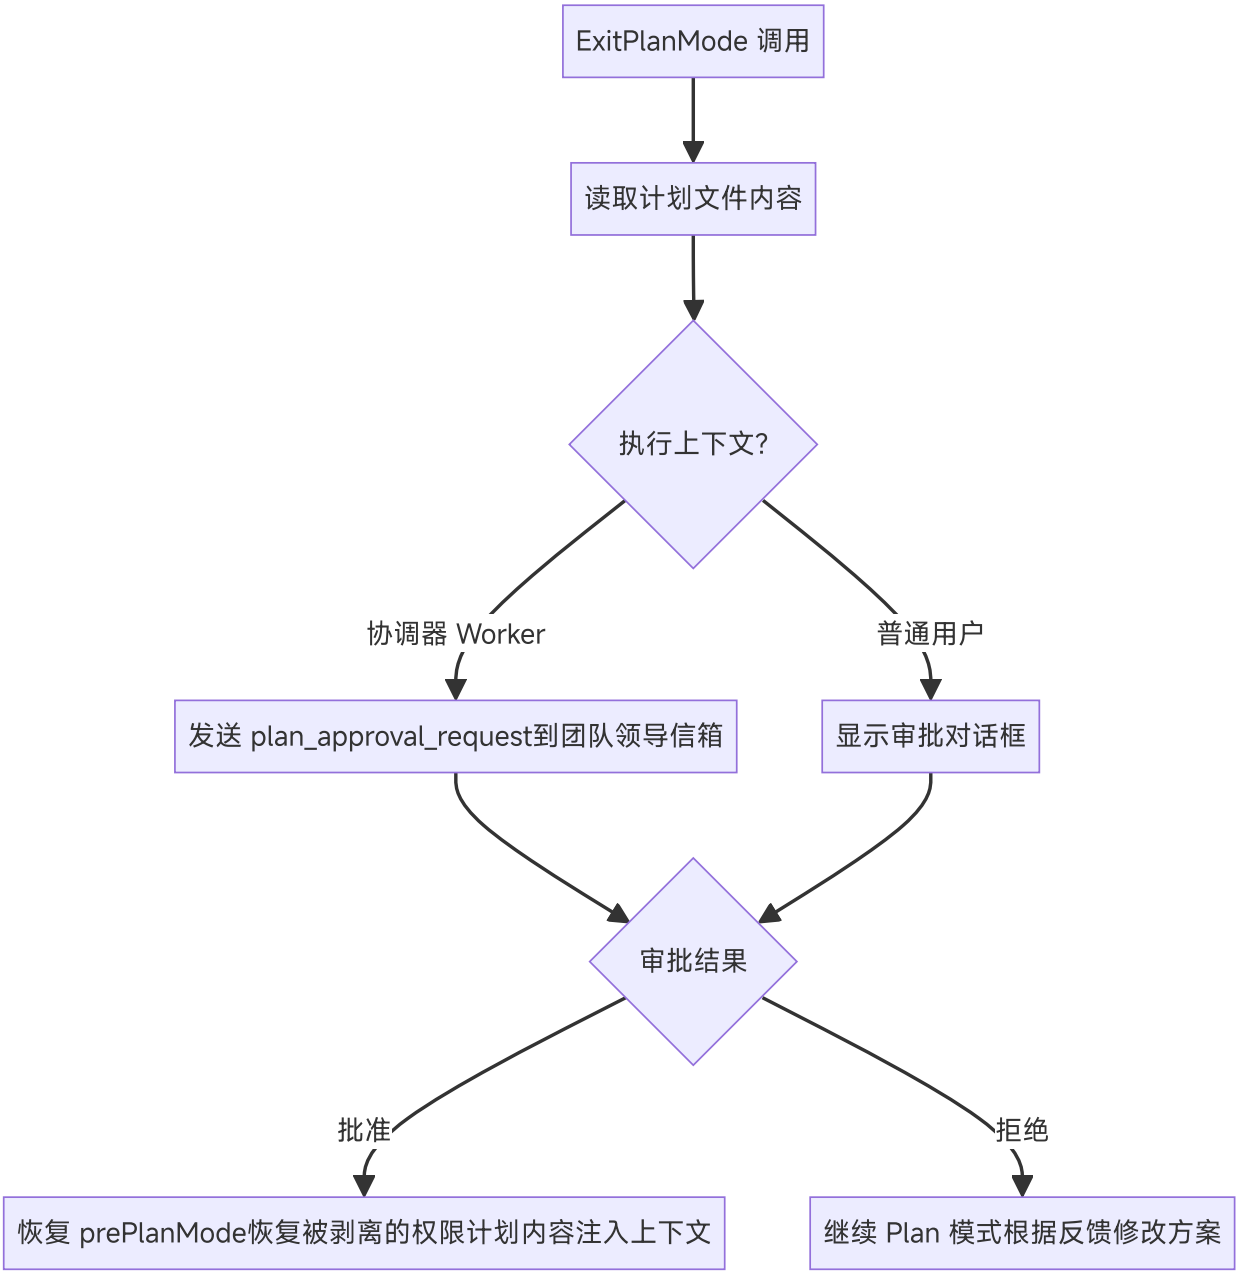

审批通过后，计划内容作为 `tool_result` 注入对话，确保模型在实施阶段能引用具体方案。

为什么需要两阶段设计?

传统的 Agent 执行模式是"边想边做"——模型一边分析问题一边修改代码。这在简单任务中效率很高，但在复杂任务中会导致:

- **方向性返工**: Agent 在只看了局部代码后就动手修改，后续发现整体方向不对，已有修改全部作废
- **无计划的局部修改**: 缺少全局视角的逐文件修改可能引入不一致，尤其在大型重构中
- **审批粒度过细**: 用户被迫逐个工具调用地审批，无法看到全貌就要做决定

两阶段设计通过一个**审批关卡**强制 Agent "先想清楚再动手"。源码中的关键约束是系统提示词中的这句话:

> "The user indicated that they do not want you to execute yet — you MUST NOT make any edits, run any non-readonly tools, or otherwise make any changes to the system."

这不是建议，是硬约束——Plan 模式下写入工具的权限被系统级剥离，即使模型尝试调用也会被拒绝。

7.7 设计洞察

1. **协调器不执行是核心约束**：防止协调器既做决策又做执行，保证任务分配的客观性。这也是为什么协调器的工具集被严格限制为 Agent + SendMessage + TaskStop。
2. **"Never write based on your findings" 是最重要的提示词设计**：强制协调器综合理解研究结果，而非将理解委托给 Worker。这个约束将协调器从消息转发器提升为真正的智能编排者。
3. **Continue vs Spawn 不是默认选择**：取决于上下文重叠度。高重叠→继续，低重叠→新建。这个决策框架避免了无脑复用或无脑新建。
4. **AbortController 独立性保证故障隔离**：一个 Worker 的崩溃不会连锁影响其他 Worker。这是并行系统的基本可靠性要求。
5. **后端检测优先级考虑用户环境**：tmux > iTerm2 > InProcess，最大化利用已有终端能力。
6. **Scratchpad 解决跨 Worker 知识共享**：没有它，Worker 之间只能通过协调器中转信息，增加延迟和信息丢失风险。
7. **Plan 模式的审批关卡是信任的物化**：两阶段设计不只是 UX 改进——它将"用户信任"从隐性（每次工具调用时的权限弹窗）变为显性（一次性审批整体方案）。这在团队协作中尤为重要：协调器 Worker 的计划需要经过团队领导审批，而不是每个文件修改都需要确认。
8. **Fork 是伪装成架构模式的缓存优化**：Fork 子 Agent 的核心动机不是"继承上下文"——而是让多个子级共享父级的 Prompt Cache。 `CacheSafeParams` 类型明确要求"字节级相同"就是最好的证据。继承上下文是缓存共享的副产品，不是设计目标。
9. **上下文隔离默认最大安全**： `createSubagentContext()` 将所有可变状态默认设为隔离（no-op / clone），开发者必须通过 `shareSetAppState` 、 `shareAbortController` 等参数显式 opt-in 共享。这种"deny by default"设计意味着新增的子 Agent 功能天生是安全的——除非开发者有意识地打开共享。
10. **工具过滤实现纵深防御**：四层独立的过滤（全局禁止 → 自定义限制 → 异步白名单 → 类型级禁止）确保即使某一层有 bug，其他层仍能拦截危险工具访问。MCP 工具的"始终放行"看似是例外，实际上是信任边界的正确划分——用户配置的外部工具由用户自己负责安全性。

> **动手实践**：在 claude-code-from-scratch 中，Agent 主循环（ `src/agent.ts` ）实现了基础的工具调用循环。尝试在此基础上增加一个简单的"plan 模式"——在执行工具前先收集所有计划的操作，让用户一次性审批。

上一章：Hooks 与可扩展性 | 下一章：记忆系统